

Рубежный контроль №1

Борисова К.А. ИУ5-62Б

Задача №1.

Для заданного набора данных проведите корреляционный анализ. В случае наличия пропусков в данных удалите строки или колонки, содержащие пропуски. Сделайте выводы о возможности построения моделей машинного обучения и о возможном вкладе признаков в модель.

```
In [1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats

plt.style.use('default')
sns.set_theme()
%matplotlib inline

df = pd.read_csv('heart.csv')
print(f"Размер данных: {df.shape}")
df.head()
```

Размер данных: (1025, 14)

```
Out[1]:
```

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal
0	52	1	0	125	212	0	1	168	0	1.0	2	2	3
1	53	1	0	140	203	1	0	155	1	3.1	0	0	3
2	70	1	0	145	174	0	1	125	1	2.6	0	0	3
3	61	1	0	148	203	0	1	161	0	0.0	2	1	3
4	62	0	0	138	294	1	1	106	0	1.9	1	3	2



```
In [2]: # Проверка пропусков
print("Пропуски в данных:")
print(df.isnull().sum())
```

Пропуски в данных:


```
age      0
sex      0
cp       0
trestbps 0
chol     0
fbs      0
restecg  0
thalach  0
exang    0
oldpeak  0
slope    0
ca       0
thal     0
target   0
dtype: int64
```

```
In [3]: corr_matrix = df.corr()

plt.figure(figsize=(12, 10))
sns.heatmap(corr_matrix, annot=True, fmt='.2f', cmap='coolwarm',
            center=0, square=True, linewidths=0.5)
plt.title('Матрица корреляций признаков')
plt.tight_layout()
plt.show()

target_corr = corr_matrix['target'].sort_values(ascending=False)
print("\nКорреляция с целевой переменной (target):")
print(target_corr)

corr_pairs = corr_matrix.unstack().sort_values(kind='quicksort', ascending=False)
corr_pairs = corr_pairs[corr_pairs < 1]
print("\n5 сильных корреляций между признаками:")
print(corr_pairs.head(10))
```



Корреляция с целевой переменной (target):

```
target      1.000000
cp          0.434854
thalach     0.422895
slope       0.345512
restecg     0.134468
fbs         -0.041164
chol        -0.099966
trestbps    -0.138772
age         -0.229324
sex         -0.279501
thal        -0.337838
ca          -0.382085
exang       -0.438029
oldpeak     -0.438441
Name: target, dtype: float64
```


5 сильных корреляций между признаками:

```
target cp      0.434854
cp target     0.434854
target thalach 0.422895
thalach target 0.422895
        slope   0.395308
slope thalach   0.395308
target slope    0.345512
slope target    0.345512
oldpeak exang   0.310844
exang oldpeak   0.310844
dtype: float64
```

```
In [4]: column_name = 'thalach'
data_column = df[column_name]

plt.figure(figsize=(10, 6))
plt.hist(data_column, bins=20, edgecolor='black', alpha=0.7, color='steelblue')
plt.xlabel(column_name, fontsize=12)
plt.ylabel('Частота', fontsize=12)
plt.title(f'Гистограмма распределения признака "{column_name}"\n(Максимальная до
plt.grid(True, alpha=0.3)
plt.axvline(data_column.mean(), color='red', linestyle='dashed', linewidth=2, la
plt.axvline(data_column.median(), color='green', linestyle='dashed', linewidth=2
plt.legend()
plt.show()

print(f"\nСтатистика для '{column_name}':")
print(f"Среднее: {data_column.mean():.2f}")
print(f"Медиана: {data_column.median():.2f}")
print(f"Стандартное отклонение: {data_column.std():.2f}")
print(f"Асимметрия: {data_column.skew():.2f}")
```



Статистика для 'thalach':
Среднее: 149.11
Медиана: 152.00
Стандартное отклонение: 23.01
Асимметрия: -0.51

Вывод:

В ходе лабораторной работы проведен корреляционный анализ данных о сердечных заболеваниях. Обнаружены значимые корреляции с целевой переменной и депрессия ST (oldpeak). В базе данных отсутствовали пропуски. Построена гистограмма признака thalach, показавшая распределение, близкое к нормальному.